

PROYECTO ML 2025-2026

Entrega parcial

Análisis inteligente de los documentos desclasificados del 23-F mediante Machine Learning, NLP y grafos

Asignatura	Machine Learning
Máster	Big Data Science
Equipo	Diego Rodrigo Gabriel Rezola Hugo Ramiro Iñigo Martínez
Repositorio Git	https://github.com/dieegordg/Proyecto-Machine-Learning-UNAV---Bayesianos-de-los-Casos
Dataset principal	Buscador RTVE de documentos desclasificados del 23-F
Documento	Informe de propuesta, metodología y planificación de mini casos

Índice

1. Resumen ejecutivo
2. Introducción y contexto
3. Objetivos del proyecto
4. Descripción del dataset
5. Metodología general de trabajo
6. Análisis exploratorio inicial previsto
7. Desarrollo por iniciativas o mini casos
 - 7.1 Mini caso 1 - Auditoría y EDA documental
 - 7.2 Mini caso 2 - Clasificación automática de documentos
 - 7.3 Mini caso 3 - Clustering temático y topic modeling
 - 7.4 Mini caso 4 - Grafo de actores, instituciones y lugares
 - 7.5 Mini caso 5 - Análisis temporal y buscador semántico
8. Plan de trabajo hasta la entrega final
9. Organización del repositorio Git y reproducibilidad
10. Riesgos, limitaciones y plan de mitigación
11. Conclusiones de la entrega parcial
12. Referencias
13. Anexos

1. Resumen ejecutivo

Este informe presenta la entrega parcial del proyecto de Machine Learning basado en los documentos desclasificados relativos al intento de golpe de Estado del 23 de febrero de 1981. La propuesta consiste en construir un pipeline reproducible para recopilar, limpiar, estructurar y analizar documentos históricos mediante técnicas de análisis exploratorio, NLP, clasificación, clustering, análisis de grafos y análisis temporal.

La finalidad no es aplicar modelos de forma aislada, sino convertir un corpus documental complejo en un sistema analítico interpretable. Para ello, se trabajará en cinco iniciativas complementarias.

La entrega parcial deja definida la estructura técnica y metodológica que se desarrollará hasta la entrega final. El informe también incluye la organización prevista del repositorio Git, los entregables técnicos, los riesgos principales y la planificación de ejecución.

2. Introducción y contexto

El 23-F constituye uno de los episodios clave de la historia democrática española. La reciente publicación y difusión de documentación desclasificada permite abordar el acontecimiento desde una perspectiva documental, cuantitativa y computacional. El corpus combina materiales procedentes de distintos organismos y ministerios, lo que abre la puerta a estudiar no solo qué se menciona en cada documento, sino también cómo se conectan actores, instituciones, fechas, lugares y temas a lo largo del tiempo.

La fuente principal del proyecto será el buscador de RTVE dedicado a los documentos desclasificados del 23-F. Esta herramienta permite consultar documentos originales, texto transcrito, resúmenes automáticos y palabras clave, como nombres propios o lugares. Como fuente complementaria se utilizará la relación oficial publicada por La Moncloa, que organiza la documentación por ministerios y organismos.

La motivación del trabajo es doble. Desde el punto de vista técnico, el dataset permite integrar distintas áreas de Machine Learning vistas en la asignatura y en el máster: NLP, clasificación supervisada, clustering, visualización, grafos e interpretación de modelos. Desde el punto de vista aplicado, el proyecto puede convertirse en una herramienta útil para investigadores, periodistas o estudiantes interesados en explorar documentos históricos de forma eficiente.

3. Objetivos del proyecto

Objetivo general

Desarrollar un análisis completo, reproducible e interpretable de los documentos desclasificados del 23-F, combinando técnicas de Machine Learning, NLP, análisis de grafos y visualización para extraer patrones documentales, temáticos, temporales y relacionales.

Objetivos específicos

- Construir un dataset estructurado con metadatos, textos limpios, palabras clave, entidades y variables derivadas.
- Realizar una auditoría de calidad del dato, prestando especial atención a OCR, duplicidades, longitud documental y disponibilidad de metadatos.
- Aplicar técnicas de clasificación supervisada para predecir categorías documentales u organismos de procedencia.
- Detectar temas latentes y grupos de documentos mediante clustering y topic modeling.
- Extraer actores, instituciones y lugares para construir un grafo de relaciones basado en coocurrencias.
- Proponer una aplicación práctica en forma de buscador semántico o sistema de recuperación de documentos relevantes.
- Documentar todo el proceso en un repositorio Git ordenado y ejecutable con rutas relativas.

4. Descripción del dataset

El dataset se compone de documentos desclasificados sobre el 23-F disponibles a través del buscador de RTVE y de la página oficial de La Moncloa. RTVE publica una lista íntegra de 167 documentos desclasificados, organizados en torno a Interior, Defensa y Exteriores. La Moncloa presenta la documentación oficial desclasificada al amparo del acuerdo del Consejo de Ministros del 24 de febrero de 2026.

Una particularidad relevante del corpus es su heterogeneidad: aparecen transcripciones telefónicas, notas informativas, informes policiales, documentación militar, expedientes diplomáticos, manuscritos y materiales con distinto grado de calidad textual. Esta variedad hace que el dataset sea idóneo para una práctica integral, pero también introduce retos de normalización, OCR, segmentación y evaluación.

4.1 Variables previstas

Tras la fase de extracción, validación y análisis exploratorio, el corpus de trabajo queda estructurado en torno a una unidad documental principal: el documento RTVE identificado mediante `doc_id`. Esta clave permite mantener la trazabilidad entre el inventario original, el texto OCR, los metadatos y las tablas derivadas.

RTVE se mantiene como fuente principal del corpus, ya que proporciona los 167 documentos y el texto OCR utilizado en el análisis. A partir de esta fuente se han generado variables de identificación, trazabilidad, contenido textual, longitud documental, calidad OCR y cobertura institucional.

Las variables principales pueden agruparse en varios bloques. En primer lugar, se mantienen variables de identificación y trazabilidad, como `doc_id`, `source_document_id`, `title`, `pages`, `detail_url` y `pdf_url`. Estas columnas permiten identificar cada documento, acceder a su fuente original y reproducir el proceso de consulta.

En segundo lugar, se conservan variables textuales y metadatos asociados, como `summary`, `keywords`, `text_full` y `text_clean_base`. El campo `text_full` contiene el texto OCR original obtenido desde RTVE, mientras que `text_clean_base` corresponde a una versión limpiada de forma conservadora, en la que se corrigen únicamente aspectos generales de formato.

También se incluyen variables de longitud, como `text_length_chars`, `text_length_words`, `text_clean_length_chars` y `text_clean_length_words`. Estas variables permiten medir la heterogeneidad del corpus y comparar documentos breves, informes largos, notas, expedientes o transcripciones extensas.

Además, se incorporan metadatos institucionales procedentes de la comparación entre RTVE y La Moncloa. Estas variables incluyen `moncloa_id`, `moncloa_section`, `moncloa_subsection`, `final_match_status` y `coverage_moncloa`. La Moncloa no sustituye a RTVE como fuente principal, sino que se utiliza como fuente comparativa para añadir información institucional cuando existe una correspondencia trazable.

Por último, se mantienen algunos indicadores generales de calidad textual, como `alpha_ratio`, `digit_ratio`, `uppercase_ratio` y `weird_char_ratio`. Estas variables se entienden como indicadores de diagnóstico, no como variables finales de modelado. Su utilidad principal es detectar posibles diferencias de calidad OCR, presencia de códigos administrativos, uso intensivo de mayúsculas o caracteres poco habituales.

El archivo principal generado tras la limpieza base es `data/processed/rve_corpus_clean_base.csv`, formado por 167 documentos y 25 columnas. Esta tabla no constituye una matriz final de entrenamiento, sino una base común sobre la que cada mini caso deberá construir su propio dataset, seleccionar sus variables y definir su pipeline de modelado.

4.2 Retos esperados del dataset

- Calidad desigual de los textos por la presencia de documentos escaneados, manuscritos o deteriorados.
- Posibles diferencias entre unidades documentales oficiales y documentos individualizados en la lista de RTVE.
- Necesidad de normalizar nombres propios y alias, por ejemplo variantes de instituciones, cargos o personas.
- Clases potencialmente desbalanceadas si se usa ministerio u organismo como variable objetivo.
- Evaluación no trivial en tareas no supervisadas, donde será necesario combinar métricas cuantitativas con revisión cualitativa.

5. Metodología general de trabajo

El proyecto seguirá una metodología incremental. Primero se construirá una base documental mínima y trazable. Después se desarrollarán transformaciones comunes reutilizables por todos los mini casos. Finalmente, cada iniciativa consumirá el dataset procesado y producirá resultados comparables e interpretables.

5.1 Pipeline de datos

- Ingesta: identificación de URLs, descarga o carga controlada de documentos y creación de metadatos.
- Extracción: obtención de texto, título, fecha, fuente, organismo y enlaces.
- Limpieza general base: normalización conservadora de saltos de línea, tabulaciones, espacios repetidos y bloques excesivos de líneas vacías, manteniendo siempre el texto OCR original.
- Procesamiento NLP específico: tokenización, stopwords, n-gramas, extracción de entidades, TF-IDF o embeddings, aplicados únicamente dentro de los mini casos que lo requieran.
- Feature engineering: TF-IDF, embeddings, recuentos de entidades, variables temporales y medidas de longitud.
- Modelado: clasificación, clustering, grafos y buscador semántico.
- Evaluación e interpretación: métricas, análisis de errores, visualizaciones y conclusiones aplicadas.

5.2 Herramientas previstas

Bloque	Herramientas	Justificación
Procesamiento	Python, pandas, numpy	Estructuración del dataset y cálculo de variables.
NLP	spaCy, scikit-learn, sentence-transformers	Tokenización, NER, TF-IDF y embeddings.
Modelado	scikit-learn, BERTopic/UMAP si procede	Clasificación, clustering y reducción de dimensionalidad.
Grafos	NetworkX, PyVis o Gephi	Construcción y visualización de redes de coocurrencia.
Visualización	matplotlib, plotly, Tableau opcional	Figuras estáticas y exploración interactiva.
Reproducibilidad	Git, requirements.txt, rutas relativas	Control de versiones y ejecución portable.

6. Análisis exploratorio inicial previsto

El análisis exploratorio general se ha desarrollado en el notebook 02_eda_documental_rtve.ipynb. Su objetivo no es resolver un mini caso concreto, sino entender la estructura, calidad, cobertura y limitaciones del corpus antes de aplicar modelos de Machine Learning o técnicas avanzadas de NLP.

El EDA se ha planteado como una fase general de diagnóstico. Por este motivo, no se han aplicado transformaciones propias de modelado, como TF-IDF, embeddings, escalado, balanceo de clases,

selección de variables o particiones train/test. Estas operaciones deberán desarrollarse dentro de cada mini caso, para evitar fugas de información entre entrenamiento y evaluación.

6.1 Integridad del Corpus

La primera comprobación realizada fue la validación de integridad del corpus. El dataset principal está formado por 167 documentos RTVE, todos ellos con texto OCR asociado. No se detectaron duplicados por doc_id, documentos del inventario sin texto ni textos vacíos.

Esta validación permite utilizar el corpus completo como base de trabajo. También confirma que el proceso de extracción inicial ha generado una estructura consistente, donde cada documento tiene un identificador único y puede relacionarse con sus metadatos, enlaces y texto completo.

6.2 Longitud documental y heterogeneidad

El análisis de longitudes muestra que el corpus es muy heterogéneo. La mayoría de los documentos son relativamente cortos, pero existen algunos textos muy extensos, como transcripciones, informes largos o recopilaciones documentales.

Esta heterogeneidad es relevante porque condiciona el diseño de los mini casos posteriores. Algunos análisis podrán trabajar a nivel de documento completo, mientras que otros, especialmente búsqueda semántica, extracción de entidades o análisis de relaciones, podrían requerir fragmentar documentos largos para evitar que unos pocos textos dominen el análisis.

Durante el EDA se analizaron variables como número de páginas, número de caracteres, número de palabras y relación entre páginas y longitud textual. Este análisis permitió identificar la presencia de documentos atípicamente largos sin eliminarlos automáticamente del corpus.

6.3 Calidad del OCR

También se realizó una revisión básica de calidad textual del OCR. Para ello se calcularon indicadores como la proporción de caracteres alfabéticos, dígitos, mayúsculas y caracteres poco habituales.

Los resultados indican que el texto OCR es aprovechable para análisis posteriores, aunque existen documentos con señales de ruido. Este ruido puede estar relacionado con documentos escaneados, formatos administrativos, tablas, códigos internos, textos en mayúsculas, manuscritos o errores propios del OCR.

Estos indicadores se utilizan únicamente como diagnóstico. No se han eliminado documentos en función de estas métricas, ya que hacerlo en una fase general podría introducir sesgos. Cada mini caso deberá decidir si necesita una limpieza adicional en función de su objetivo concreto.

6.4 Cobertura institucional de La Moncloa

RTVE se mantiene como fuente principal del corpus, ya que proporciona los 167 documentos y el texto OCR utilizado en el proyecto. La Moncloa se utiliza como fuente comparativa para incorporar metadatos institucionales cuando existe una correspondencia trazable.

La tabla data/interim/source_comparison.csv contiene la correspondencia final entre ambas fuentes. Esta correspondencia fue generada previamente en el notebook 01_data_sources_and_dataset.ipynb mediante un método de similitud consciente de la fecha (date_aware_one_to_one_similarity). La tabla final contiene 155 correspondencias y no presenta duplicados ni por documento RTVE ni por documento Moncloa, por lo que representa una relación uno a uno entre los documentos emparejados.

A partir de esta correspondencia, 155 documentos RTVE incorporan información institucional procedente de La Moncloa, como `moncloa_section` y `moncloa_subsection`. Los 12 documentos restantes no tienen una correspondencia final trazable y se mantienen sin etiqueta institucional.

Esta decisión es importante desde el punto de vista metodológico. No se han rellenado automáticamente las etiquetas de esos 12 documentos, ya que hacerlo implicaría introducir una clasificación no justificada en la base general. Si algún mini caso necesita trabajar con una etiqueta institucional completa, deberá tratar estos casos de forma explícita mediante exclusión, revisión manual o reglas documentadas.

6.5 Metadatos auxiliares

El corpus incluye campos auxiliares como `summary` y `keywords`. Ambos están completos para los 167 documentos, pero su análisis muestra que deben utilizarse con cautela.

El campo `summary` tiene una longitud fija y todos los registros terminan en puntos suspensivos, lo que indica que probablemente se trata de un texto recortado o limitado por la fuente. Por tanto, puede servir como apoyo para una lectura rápida, pero no debería sustituir al texto completo en los análisis principales.

El campo `keywords` también está completo, aunque muchos valores contienen fechas, códigos internos o referencias administrativas. Por ello, no debe interpretarse directamente como una lista limpia de etiquetas semánticas. Su uso como variable de entrada en modelos deberá valorarse dentro de cada mini caso.

6.6 Señal textual general

Como cierre del EDA general, se realizó una revisión básica del vocabulario del corpus. El objetivo era comprobar si el texto OCR contenía señales coherentes con el dominio documental del 23-F.

Los términos más frecuentes incluyen cargos militares, instituciones, actores y lugares asociados al contexto histórico analizado, como general, coronel, guardia, tejero, militar, armada, rey, madrid o gobierno.

También se identificaron bigramas interpretables, como guardia civil, teniente coronel, coronel tejero, justicia militar, consejo supremo o fuerzas armadas. Esta revisión confirma que el texto completo conserva información útil para análisis posteriores de clasificación, agrupación temática, relaciones entre entidades o búsqueda semántica.

6.7 Limpieza general base

Tras el EDA se ha desarrollado el notebook `03_limpieza_general_corpus.ipynb`, cuyo objetivo es generar una versión base del corpus con una limpieza textual conservadora.

La limpieza aplicada conserva siempre el texto original en la columna `text_full` y crea una nueva columna llamada `text_clean_base`. Esta versión limpia normaliza saltos de línea, tabulaciones, espacios repetidos y bloques excesivos de líneas vacías. No elimina palabras, números, signos de puntuación, nombres propios ni stopwords.

Tampoco se aplican transformaciones propias de modelado, como TF-IDF, embeddings, escalado, balanceo de clases o partición train/test. La razón es evitar cualquier forma de fuga de información y dejar que cada mini caso construya su propio pipeline de preprocesado y modelado.

Antes de guardar la base limpia se revisaron las columnas disponibles. Se eliminaron columnas constantes o puramente auxiliares del EDA, como indicadores que tenían el mismo valor para todos los documentos o variables intermedias utilizadas solo para diagnóstico. La tabla final conserva identificación, trazabilidad,

texto original, texto limpio, longitudes básicas, metadatos institucionales y algunos indicadores generales de calidad.

El resultado final es el archivo `data/processed/rve_corpus_clean_base.csv`, con 167 documentos y 25 columnas. Esta tabla se considera una base común de trabajo, pero no una matriz final de entrenamiento. Cada mini caso deberá decidir qué documentos utiliza, cuál es su variable objetivo, qué columnas excluye y qué transformaciones aplica dentro de su propio flujo metodológico.

7. Desarrollo por iniciativas o mini casos

La propuesta incluye cinco mini casos. Los cuatro primeros cubren el mínimo obligatorio de iniciativas y el quinto añade una aplicación práctica con valor añadido. Todos compartirán el mismo dataset procesado y estarán conectados por un mismo pipeline.

7.1 Mini caso 1 - Clasificación automática de documentos por procedencia institucional

1. Objetivo del mini caso

El objetivo de este mini caso es entrenar un modelo de clasificación supervisada capaz de predecir la procedencia institucional de un documento a partir de su contenido textual.

La variable objetivo será `moncloa_section`, que clasifica los documentos según la sección institucional identificada en la comparación con La Moncloa: principalmente `defensa`, `interior` y `exteriores`.

2. Justificación

Este caso permite aprovechar la información institucional obtenida durante la validación del corpus. Aunque RTVE es la fuente principal de trabajo, la comparación con La Moncloa aporta una etiqueta útil para una parte importante de los documentos.

A partir de esta etiqueta, se puede plantear un problema supervisado: comprobar si el contenido textual de un documento contiene suficiente señal para inferir su procedencia institucional. Esto puede ser útil para clasificar documentos nuevos o documentos sin metadatos institucionales explícitos.

Además, este mini caso complementa los enfoques no supervisados del proyecto, ya que introduce una tarea con variable objetivo definida y evaluación cuantitativa.

3. Datos necesarios

Se utiliza principalmente el archivo:

`data/processed/rve_corpus_clean_base.csv`

Las variables principales son:

- `text_clean_base` como fuente textual principal;
- `doc_id` para trazabilidad;
- `moncloa_section` como variable objetivo;
- `title` como posible apoyo en una versión secundaria del modelo.

Solo se utilizarán para entrenamiento y evaluación los documentos que tienen `moncloa_section` no nulo. Esto deja 155 documentos etiquetados. Los 12 documentos restantes, presentes en RTVE pero sin equivalente directo detectado en La Moncloa, no se usarán para entrenar el modelo, aunque podrían clasificarse posteriormente como documentos no etiquetados.

Es importante excluir como variables predictoras columnas que puedan generar fuga de información, como `moncloa_id`, `moncloa_section`, `moncloa_subsection`, `final_match_status` o `coverage_moncloa`, ya que están directa o indirectamente relacionadas con la etiqueta que se quiere predecir.

4. Validación de viabilidad

El caso es viable porque existen 155 documentos con etiqueta institucional disponible y todos ellos cuentan con texto limpio en `text_clean_base`.

El EDA general mostró que el corpus contiene señal textual suficiente, con presencia de términos relacionados con instituciones, cargos, actores militares y contexto judicial o político. Esto permite pensar que un modelo de clasificación textual puede capturar diferencias entre secciones institucionales.

No obstante, la distribución de clases no está equilibrada: predominan los documentos de `defensa`, seguidos por `interior` y `exteriores`. Por ello, será necesario usar validación estratificada y métricas que no dependan únicamente de la clase mayoritaria.

5. Metodología propuesta

Se plantea el siguiente flujo:

- selección de documentos con `moncloa_section` disponible;
- definición de `text_clean_base` como variable principal de entrada;
- separación entre variables predictoras y variable objetivo;
- vectorización textual mediante TF-IDF;
- entrenamiento de modelos lineales de clasificación, como Regresión Logística o Linear SVM;
- evaluación mediante validación estratificada;
- análisis de resultados con accuracy, macro F1 y matriz de confusión;
- revisión de los errores de clasificación para detectar clases difíciles o documentos ambiguos.

Como versión secundaria, se podría probar una entrada combinada de `title` + `text_clean_base`, siempre comparándola con el modelo base para comprobar si aporta mejora real.

El desarrollo técnico se plantea en el notebook

`04_caso_uso1_clasificacion_institucional.ipynb`.

6. Riesgos y limitaciones

- muestra relativamente pequeña para clasificación supervisada;
- desbalance entre secciones institucionales;
- riesgo de fuga de información si se usan metadatos derivados de La Moncloa como variables predictoras;
- posibilidad de que el modelo aprenda patrones de formato en lugar de contenido semántico;
- ruido OCR que puede afectar a la vectorización textual;
- los 12 documentos sin etiqueta Moncloa quedan fuera del entrenamiento y requerirían revisión o clasificación posterior.

7.2 Mini caso 2 - Clustering temático y topic modeling

1. Objetivo del mini caso

El objetivo de este mini caso es identificar estructuras temáticas latentes en el corpus documental mediante técnicas de clustering y modelado de tópicos, con el fin de agrupar documentos en función de su contenido semántico sin necesidad de etiquetas previas.

2. Justificación

Dado que el dataset carece de una categorización explícita completa y presenta una alta heterogeneidad documental, el uso de técnicas no supervisadas permite descubrir patrones ocultos, identificar bloques temáticos (militar, político, judicial, etc.) y facilitar una mejor comprensión global del corpus.

3. Datos necesarios

Se utilizan principalmente:

- text_clean_base como fuente textual principal;
- doc_id para trazabilidad;
- variables de longitud (text_length_words) para filtrado;
- opcionalmente keywords y summary como apoyo interpretativo.

4. Validación de viabilidad

El corpus cuenta con 167 documentos, todos con texto OCR disponible, lo que permite aplicar técnicas de clustering. La calidad textual es variable pero suficiente para extraer señal semántica, como se comprobó en el EDA.

El problema es de naturaleza no supervisada, por lo que no requiere etiquetas previas. La heterogeneidad del corpus refuerza la idoneidad del enfoque.

5. Metodología propuesta

Se plantea el siguiente flujo:

1. preprocesamiento textual específico (tokenización, limpieza, lematización);
2. vectorización mediante TF-IDF o embeddings;
3. aplicación de algoritmos de clustering (K-Means, HDBSCAN);
4. evaluación mediante métricas internas (Silhouette Score);
5. interpretación de clusters mediante palabras clave;
6. visualización en espacios reducidos (PCA o UMAP).

El desarrollo técnico se encuentra detallado en el notebook **05_caso_uso2.ipynb**.

6. Riesgos y limitaciones

- sensibilidad a ruido del OCR;
- dificultad en la interpretación de clusters;
- elección del número óptimo de clusters;
- posible dominancia de documentos largos;
- ausencia de ground truth para validación externa.

7.3 Mini caso 3 - Grafo de actores, instituciones y lugares

1. Objetivo del mini caso

El objetivo es construir un grafo de relaciones entre entidades (personas, instituciones y lugares) extraídas del corpus, con el fin de analizar la estructura relacional del contexto histórico del 23-F.

2. Justificación

El dataset contiene una gran cantidad de información sobre actores relevantes. Modelar estas relaciones mediante grafos permite:

- identificar actores centrales;
- analizar redes de poder;
- descubrir conexiones no evidentes entre documentos.

3. Datos necesarios

Se utilizan:

- text_clean_base como fuente textual;
- doc_id para trazabilidad;
- entidades extraídas mediante técnicas de NLP;
- opcionalmente metadatos institucionales para enriquecer el análisis.

4. Validación de viabilidad

El corpus presenta una fuerte señal en términos de entidades (nombres propios, instituciones, cargos), como se observó en el EDA. Esto permite aplicar técnicas de reconocimiento de entidades (NER).

El problema es exploratorio, sin necesidad de etiquetas previas.

5. Metodología propuesta

El flujo planteado es:

1. extracción de entidades mediante modelos NLP;
2. filtrado por tipo (persona, organización, localización);
3. construcción de relaciones basadas en co-ocurrencia;
4. generación de un grafo con NetworkX;
5. análisis de centralidad y comunidades;
6. visualización del grafo.

El detalle de implementación se encuentra en el notebook **06_caso_uso3.ipynb**.

6. Riesgos y limitaciones

- errores de NER debido al OCR;
- falta de normalización de entidades (alias);
- ruido en relaciones por co-ocurrencia;
- grafos densos difíciles de interpretar;
- ausencia de validación objetiva del grafo.

7.4 Mini caso 4 - Asistente documental semántico

1. Objetivo del mini caso

El objetivo de este mini caso es plantear un sistema de búsqueda semántica y respuesta asistida sobre el corpus documental del 23-F.

La finalidad es que un usuario pueda formular consultas sobre los documentos y obtener como resultado los documentos o fragmentos más relevantes, manteniendo siempre la trazabilidad mediante `doc_id`, título y enlace al PDF original.

El sistema no se plantea inicialmente como un chatbot completo, sino como un asistente documental capaz de facilitar la exploración del corpus.

2. Justificación

El corpus contiene 167 documentos con texto limpio disponible, pero presenta una fuerte heterogeneidad en extensión y contenido. Algunos documentos son breves, mientras que otros superan ampliamente las 10.000 palabras.

Esto hace que una búsqueda manual o puramente literal sea limitada, especialmente cuando el usuario quiere localizar información sobre actores, instituciones, eventos o temas concretos.

Un sistema de búsqueda semántica permitiría consultar el corpus de forma más flexible, recuperando documentos o fragmentos relevantes aunque la pregunta del usuario no coincida literalmente con las palabras del texto.

Además, este mini caso aporta una aplicación práctica vinculada a NLP y GenAI, ya que puede evolucionar hacia un sistema tipo RAG siempre que las respuestas se basen exclusivamente en evidencias recuperadas del corpus.

3. Datos necesarios

Se utiliza principalmente el archivo:

`data/processed/rtve_corpus_clean_base.csv`

Las variables principales son:

- `text_clean_base` como fuente textual principal;
- `doc_id` para trazabilidad;
- `title` para identificar el documento;
- `pdf_url` para acceder al documento original;
- `moncloa_section` como posible metadato de contexto;
- `text_clean_length_words` para decidir si un documento debe fragmentarse.

El análisis inicial muestra que los 167 documentos tienen texto limpio disponible y no existen textos vacíos.

4. Validación de viabilidad

El mini caso es viable porque todos los documentos del corpus tienen texto limpio disponible. Esto permite construir un sistema de recuperación documental basado en similitud textual o semántica.

La revisión de longitudes muestra que la mediana del corpus es de 579 palabras, mientras que la media asciende a 2.075 palabras. Esta diferencia indica que existen documentos muy extensos que elevan la media.

Además:

- 63 documentos tienen más de 1.000 palabras;
- 18 documentos tienen más de 3.000 palabras;
- 9 documentos tienen más de 5.000 palabras;
- 6 documentos tienen más de 10.000 palabras;
- el documento más largo alcanza 95.293 palabras.

Esto confirma que el sistema no debería depender únicamente de documentos completos. Para consultas concretas, será necesario trabajar con fragmentos o `chunks`, especialmente en documentos largos.

5. Metodología propuesta

Se plantea el siguiente flujo:

- selección del texto limpio `text_clean_base` como base documental;
- división de documentos largos en fragmentos;
- generación de representaciones vectoriales mediante TF-IDF como baseline;
- posible uso posterior de embeddings semánticos;
- recuperación de los documentos o fragmentos más relevantes mediante similitud coseno;
- devolución de resultados con evidencia trazable: fragmento, `doc_id`, título, enlace al PDF y score de similitud;
- incorporación opcional de una capa de respuesta asistida con LLM, siempre condicionada a utilizar solo los fragmentos recuperados.

El sistema podrá tener dos funcionalidades principales:

- búsqueda por pregunta del usuario;
- recomendación de documentos relacionados a partir de un documento inicial.

El desarrollo técnico se encuentra planteado en el notebook

`07_caso_uso4_asistente_semantico.ipynb`.

6. Riesgos y limitaciones

- necesidad de fragmentar documentos largos para mejorar la precisión de la recuperación;
- ruido OCR que puede afectar a la calidad de la búsqueda;
- ausencia de un conjunto de preguntas y respuestas etiquetado para evaluación objetiva;
- posible recuperación de documentos parecidos pero no necesariamente relevantes;
- riesgo de respuestas no justificadas si se incorpora un LLM sin control de evidencias;
- evaluación inicialmente cualitativa, basada en revisión manual de resultados.

Para reducir estos riesgos, el sistema deberá priorizar la trazabilidad y mostrar siempre los documentos o fragmentos usados como evidencia.

7.5 Mini caso 5 - Generación automática de fichas/resúmenes documentales

1. Objetivo del mini caso

El objetivo de este mini caso es generar fichas documentales estructuradas a partir del texto limpio de cada documento del corpus.

La finalidad es disponer de una representación resumida y organizada de cada documento, que facilite su lectura, comparación y reutilización en otros análisis del proyecto.

Estas fichas podrían incluir información como resumen corto, resumen extendido, actores principales, instituciones mencionadas, fechas relevantes, temas clave y enlace al PDF original.

2. Justificación

El corpus ya contiene una columna `summary`, pero el análisis realizado muestra que estos resúmenes

tienen una limitación importante: todos los documentos tienen un resumen de exactamente 303 caracteres y todos terminan en

Esto confirma que los resúmenes disponibles están recortados de forma sistemática y no deben interpretarse como resúmenes completos del contenido documental.

Dado que algunos documentos son muy extensos, el resumen actual resulta insuficiente para comprender adecuadamente su contenido. Por ello, se plantea la generación automática de fichas documentales más completas a partir de `text_clean_base`.

Además, este mini caso puede actuar como una capa transversal de enriquecimiento documental, útil para apoyar otros mini casos del proyecto.

3. Datos necesarios

Se utiliza principalmente el archivo:

`data/processed/rtve_corpus_clean_base.csv`

Las variables principales son:

- `doc_id` para trazabilidad;
- `title` como identificación del documento;
- `summary` como resumen original limitado;
- `text_clean_base` como fuente textual principal;
- `text_clean_length_words` para analizar la extensión del documento;
- `moncloa_section` como posible metadato institucional;
- `pdf_url` para acceder al documento original.

La ficha documental propuesta incluiría campos como:

- resumen corto;
- resumen extendido;
- actores principales;
- instituciones mencionadas;
- fechas relevantes;
- temas clave;
- enlace al PDF original.

4. Validación de viabilidad

El mini caso es viable porque los 167 documentos del corpus tienen texto limpio disponible y no existen textos vacíos.

Además, se comprueba que el campo `summary` está completo, pero es limitado:

- 167 resúmenes disponibles;
- 0 resúmenes vacíos;
- todos los resúmenes tienen 303 caracteres;
- todos los resúmenes terminan en

La comparación entre `summary` y `text_clean_base` confirma que el resumen actual representa solo una parte reducida del contenido. La mediana del resumen es de 49 palabras, mientras que la mediana del texto

limpio es de 579 palabras. Además, el ratio mediano entre resumen y texto completo es aproximadamente 0,082.

En documentos largos, esta proporción es todavía menor. Por tanto, existe margen claro para construir fichas documentales más informativas.

5. Metodología propuesta

Se plantea el siguiente flujo:

- selección de `text_clean_base` como fuente principal;
- revisión de la longitud de cada documento;
- fragmentación de documentos largos si es necesario;
- generación de una ficha estructurada por documento;
- extracción o generación de:
 - resumen corto;
 - resumen extendido;
 - actores principales;
 - instituciones mencionadas;
 - fechas relevantes;
 - temas clave;
- mantenimiento de trazabilidad mediante `doc_id`, `title` y `pdf_url`;
- validación manual de una muestra de fichas generadas.

La generación podría abordarse mediante dos enfoques:

- enfoque extractivo, seleccionando frases relevantes del propio texto;
- enfoque generativo controlado, usando un modelo de lenguaje con instrucciones estrictas para no introducir información externa al documento.

El desarrollo técnico se encuentra planteado en el notebook

`08_caso_uso5_fichas_documentales.ipynb`.

6. Riesgos y limitaciones

- riesgo de generar información no presente en el documento si se usa un modelo generativo sin control;
- pérdida de matices en documentos muy largos;
- ruido OCR que puede afectar a la calidad de los resúmenes;
- dificultad para evaluar automáticamente la calidad de las fichas;
- necesidad de revisión manual de una muestra de resultados;
- posible dependencia de modelos externos si se usa un LLM.

Para reducir estos riesgos, la metodología deberá mantener siempre la trazabilidad al documento original y utilizar el texto del corpus como única fuente de información.

8. Organización del repositorio Git y reproducibilidad

El repositorio Git será obligatorio durante el desarrollo. La estructura propuesta busca separar datos, notebooks, scripts, resultados y documentación. El notebook principal funcionará como punto de entrada y llamará a funciones definidas en scripts auxiliares.

Ruta	Contenido
README.md	Descripción del proyecto, instrucciones de ejecución y autores.

requirements.txt	Librerías necesarias.
notebooks/	Todos los notebooks del proyecto
src/	Scripts de descarga, limpieza, features, modelos y visualización.
data/raw/	Datos originales o enlaces controlados.
data/interim/	Textos y metadatos intermedios.
data/processed/	Dataset final procesado.
outputs/figures/	Figuras del informe y anexos.
outputs/models/	Modelos entrenados si procede.
docs/	Informe parcial, informe final y presentación.

Criterios de reproducibilidad

- Todas las rutas serán relativas al directorio raíz del proyecto.
- El notebook principal se podrá ejecutar de principio a fin sin modificar rutas manualmente.
- Los scripts auxiliares estarán documentados y versionados.
- Los resultados intermedios pesados se guardarán en carpetas separadas y, si es necesario, se excluirán de Git mediante .gitignore.
- Las figuras usadas en el informe se generarán desde el código o quedarán documentadas en el repositorio.

9. Conclusiones de la entrega parcial

La propuesta presentada cumple el objetivo de la entrega intermedia: define una estructura clara del trabajo, describe las iniciativas de análisis y concreta cómo se abordará cada mini caso. El proyecto se plantea como una investigación documental apoyada en Machine Learning, con especial énfasis en la reproducibilidad, la interpretación y la utilidad práctica.

La combinación de EDA, clasificación, clustering, grafos, análisis temporal y búsqueda semántica permite cubrir distintas áreas de conocimiento y construir una narrativa sólida sobre el corpus. La fase siguiente consistirá en consolidar el dataset procesado, ejecutar los modelos, evaluar resultados y transformar los hallazgos en un informe final claro y defendible.

10. Referencias

1. Enunciado de la asignatura: Proyecto ML 2025-2026. Documento facilitado por el profesorado.
2. RTVE. (2026). Buscador 23F | Lee y explora todos los documentos desclasificados con ayuda de la IA. <https://www.rtve.es/noticias/20260227/buscador-23f-lee-explora-todos-documentos-desclasificados-con-ayuda-ia/16956459.shtml>
3. RTVE. (2026). Todos los documentos desclasificados del 23F: consulta la lista íntegra. <https://www.rtve.es/noticias/20260225/todos-documentos-desclasificados-23f-lista-integra/16954095.shtml>
4. RTVE. (2026). RTVE crea con IA el buscador de documentos desclasificados del 23-F. <https://www.rtve.es/rtve/20260227/rtve-crea-ia-buscador-documentos-desclasificados-23-f/16957045.shtml>
5. La Moncloa. (2026). Documentos desclasificados relativos al 23-F. <https://www.lamoncloa.gob.es/consejodeministros/paginas/desclasificacion-documentos-23f.aspx>
6. Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research.
7. Honnibal, M. & Montani, I. spaCy 2: Natural language understanding with Bloom embeddings, convolutional neural networks and incremental parsing.
8. McInnes, L., Healy, J. & Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction.

11. Anexos

Anexo A - Estructura del repositorio

```
proyecto-ml-23f/  
|-- README.md  
|-- requirements.txt  
|-- notebooks/  
|-- src/  
|-- data/    (raw/, interim/, processed/)  
|-- outputs/ (figures/, tables/, models/)  
`-- docs/    (informe_intermedio.pdf, informe_final.pdf)
```