

PROYECTO ML 2025-2026

Entrega parcial

Análisis inteligente de los documentos desclasificados del 23-F mediante Machine Learning, NLP y grafos

Asignatura	Machine Learning
Máster	Big Data Science
Equipo	Diego Rodrigo Gabriel Rezola Hugo Ramiro Iñigo Martínez
Fecha de entrega parcial	3 de mayo de 2026, 23:59
Repositorio Git	https://github.com/dieegordg/Proyecto-Machine-Learning-UNAV---Bayesianos-de-los-Ca-dos
Dataset principal	Buscador RTVE de documentos desclasificados del 23-F
Documento	Informe de propuesta, metodología y planificación de mini casos

Nota: este documento queda preparado para la entrega intermedia con los datos del equipo y el repositorio ya incorporados. Los permisos del repositorio deben confirmarse externamente antes del envío.

Índice

1. Resumen ejecutivo
2. Introducción y contexto
3. Objetivos del proyecto
4. Descripción del dataset
5. Metodología general de trabajo
6. Análisis exploratorio inicial previsto
7. Desarrollo por iniciativas o mini casos
 - 7.1 Mini caso 1 - Auditoría y EDA documental
 - 7.2 Mini caso 2 - Clasificación automática de documentos
 - 7.3 Mini caso 3 - Clustering temático y topic modeling
 - 7.4 Mini caso 4 - Grafo de actores, instituciones y lugares
 - 7.5 Mini caso 5 - Análisis temporal y buscador semántico
8. Plan de trabajo hasta la entrega final
9. Organización del repositorio Git y reproducibilidad
10. Riesgos, limitaciones y plan de mitigación
11. Conclusiones de la entrega parcial
12. Referencias
13. Anexos

1. Resumen ejecutivo

Este informe presenta la entrega parcial del proyecto de Machine Learning basado en los documentos desclasificados relativos al intento de golpe de Estado del 23 de febrero de 1981. La propuesta consiste en construir un pipeline reproducible para recopilar, limpiar, estructurar y analizar documentos históricos mediante técnicas de análisis exploratorio, NLP, clasificación, clustering, análisis de grafos y análisis temporal.

La finalidad no es aplicar modelos de forma aislada, sino convertir un corpus documental complejo en un sistema analítico interpretable. Para ello, se trabajará en cinco iniciativas complementarias: auditoría y EDA documental, clasificación automática de documentos, agrupación temática no supervisada, grafo de actores e instituciones y análisis temporal con un prototipo de recuperación semántica.

La entrega parcial deja definida la estructura técnica y metodológica que se desarrollará hasta la entrega final. El informe también incluye la organización prevista del repositorio Git, los entregables técnicos, los riesgos principales y la planificación de ejecución.

2. Introducción y contexto

El 23-F constituye uno de los episodios clave de la historia democrática española. La reciente publicación y difusión de documentación desclasificada permite abordar el acontecimiento desde una perspectiva documental, cuantitativa y computacional. El corpus combina materiales procedentes de distintos organismos y ministerios, lo que abre la puerta a estudiar no solo qué se menciona en cada documento, sino también cómo se conectan actores, instituciones, fechas, lugares y temas a lo largo del tiempo.

La fuente principal del proyecto será el buscador de RTVE dedicado a los documentos desclasificados del 23-F. Esta herramienta permite consultar documentos originales, texto transcrito, resúmenes automáticos y palabras clave, como nombres propios o lugares. Como fuente complementaria se utilizará la relación oficial publicada por La Moncloa, que organiza la documentación por ministerios y organismos.

La motivación del trabajo es doble. Desde el punto de vista técnico, el dataset permite integrar distintas áreas de Machine Learning vistas en la asignatura y en el máster: NLP, clasificación supervisada, clustering, visualización, grafos, series temporales e interpretación de modelos. Desde el punto de vista aplicado, el proyecto puede convertirse en una herramienta útil para investigadores, periodistas o estudiantes interesados en explorar documentos históricos de forma eficiente.

3. Objetivos del proyecto

Objetivo general

Desarrollar un análisis completo, reproducible e interpretable de los documentos desclasificados del 23-F, combinando técnicas de Machine Learning, NLP, análisis de grafos y visualización para extraer patrones documentales, temáticos, temporales y relacionales.

Objetivos específicos

- Construir un dataset estructurado con metadatos, textos limpios, palabras clave, entidades y variables derivadas.
- Realizar una auditoría de calidad del dato, prestando especial atención a OCR, duplicidades, longitud documental y disponibilidad de metadatos.
- Aplicar técnicas de clasificación supervisada para predecir categorías documentales u organismos de procedencia.
- Detectar temas latentes y grupos de documentos mediante clustering y topic modeling.
- Extraer actores, instituciones y lugares para construir un grafo de relaciones basado en coocurrencias.
- Analizar la evolución temporal de temas, actores y documentos antes, durante y después del 23-F.

- Proponer una aplicación práctica en forma de buscador semántico o sistema de recuperación de documentos relevantes.
- Documentar todo el proceso en un repositorio Git ordenado y ejecutable con rutas relativas.

4. Descripción del dataset

El dataset se compone de documentos desclasificados sobre el 23-F disponibles a través del buscador de RTVE y de la página oficial de La Moncloa. RTVE publica una lista íntegra de 167 documentos desclasificados, organizados en torno a Interior, Defensa y Exteriores. La Moncloa presenta la documentación oficial desclasificada al amparo del acuerdo del Consejo de Ministros del 24 de febrero de 2026.

Una particularidad relevante del corpus es su heterogeneidad: aparecen transcripciones telefónicas, notas informativas, informes policiales, documentación militar, expedientes diplomáticos, manuscritos y materiales con distinto grado de calidad textual. Esta variedad hace que el dataset sea idóneo para una práctica integral, pero también introduce retos de normalización, OCR, segmentación y evaluación.

4.1 Variables previstas

Variable	Tipo	Descripción	Uso analítico
doc_id	Identificador	Clave única de cada documento.	Trazabilidad y unión de tablas.
título	Texto	Título o descripción oficial del documento.	EDA, clasificación, búsqueda.
ministerio	Categórica	Interior, Defensa, Exteriores u otra fuente.	EDA, target supervisado.
organismo	Categórica	Guardia Civil, Policía, CNI/CESID, Exteriores, etc.	Clasificación y análisis institucional.
fecha_documento	Fecha	Fecha asociada al documento, cuando esté disponible.	Series temporales.
url_origen	Texto	URL del documento o página de consulta.	Reproducibilidad.
texto_raw	Texto largo	Texto transcrito original.	NLP y auditoría de calidad.
texto_limpio	Texto largo	Texto normalizado tras preprocesado.	Modelos y análisis.
keywords	Lista	Palabras clave, entidades o etiquetas disponibles.	Feature engineering.
num_tokens	Númérica	Longitud estimada del documento.	EDA y control de outliers.
entidades	Lista	Personas, organizaciones, lugares y fechas extraídas.	Grafo y análisis temporal.

4.2 Retos esperados del dataset

- Calidad desigual de los textos por la presencia de documentos escaneados, manuscritos o deteriorados.
- Posibles diferencias entre unidades documentales oficiales y documentos individualizados en la lista de RTVE.
- Necesidad de normalizar nombres propios y alias, por ejemplo variantes de instituciones, cargos o personas.

- Clases potencialmente desbalanceadas si se usa ministerio u organismo como variable objetivo.
- Evaluación no trivial en tareas no supervisadas, donde será necesario combinar métricas cuantitativas con revisión cualitativa.

5. Metodología general de trabajo

El proyecto seguirá una metodología incremental. Primero se construirá una base documental mínima y trazable. Después se desarrollarán transformaciones comunes reutilizables por todos los mini casos. Finalmente, cada iniciativa consumirá el dataset procesado y producirá resultados comparables e interpretables.

5.1 Pipeline de datos

- Ingesta: identificación de URLs, descarga o carga controlada de documentos y creación de metadatos.
- Extracción: obtención de texto, título, fecha, fuente, organismo y enlaces.
- Limpieza: normalización de saltos de línea, caracteres extraños, mayúsculas, espacios, encabezados repetidos y ruido OCR.
- Procesamiento NLP: tokenización, lematización, eliminación controlada de stopwords, n-gramas y extracción de entidades.
- Feature engineering: TF-IDF, embeddings, recuentos de entidades, variables temporales y medidas de longitud.
- Modelado: clasificación, clustering, grafos y análisis temporal.
- Evaluación e interpretación: métricas, análisis de errores, visualizaciones y conclusiones aplicadas.

5.2 Herramientas previstas

Bloque	Herramientas	Justificación
Procesamiento	Python, pandas, numpy	Estructuración del dataset y cálculo de variables.
NLP	spaCy, scikit-learn, sentence-transformers	Tokenización, NER, TF-IDF y embeddings.
Modelado	scikit-learn, BERTopic/UMAP si procede	Clasificación, clustering y reducción de dimensionalidad.
Grafos	NetworkX, PyVis o Gephi	Construcción y visualización de redes de coocurrencia.
Visualización	matplotlib, plotly, Tableau opcional	Figuras estáticas y exploración interactiva.
Reproducibilidad	Git, requirements.txt, rutas relativas	Control de versiones y ejecución portable.

6. Análisis exploratorio inicial previsto

El EDA será la base del resto del proyecto. Su objetivo es entender la estructura, calidad, cobertura y limitaciones del corpus antes de aplicar modelos. En la entrega final, este apartado incluirá métricas descriptivas y visualizaciones generadas desde el notebook principal.

Pregunta de EDA	Variable o técnica	Salida prevista
¿Cuántos documentos hay por ministerio u organismo?	ministerio, organismo	Tabla y gráfico de barras.
¿Qué periodo cubre el corpus?	fecha_documento, fechas extraídas	Línea temporal y conteo por año/mes.
¿Qué documentos son más extensos?	num_tokens, num_paginas	Histograma y ranking de documentos.

¿Qué calidad tiene el texto?	ruido OCR, caracteres raros, proporción de tokens válidos	Indicadores de calidad y ejemplos.
¿Qué palabras y n-gramas dominan?	TF, TF-IDF, n-gramas	Tablas de términos y nube de palabras opcional.
¿Qué actores e instituciones aparecen con más frecuencia?	NER	Ranking de entidades y preparación del grafo.

Las visualizaciones principales se documentarán en el informe y se incluirán en anexos siguiendo el criterio de trazabilidad exigido para figuras y tablas.

7. Desarrollo por iniciativas o mini casos

La propuesta incluye cinco mini casos. Los cuatro primeros cubren el mínimo obligatorio de iniciativas y el quinto añade una aplicación práctica con valor añadido. Todos compartirán el mismo dataset procesado y estarán conectados por un mismo pipeline.

7.1 Mini caso 1 - Auditoría y EDA documental

Planteamiento inicial

Antes de aplicar modelos, se analizará la estructura y calidad del corpus para determinar qué información es fiable, qué variables pueden emplearse y qué limitaciones deben reconocerse.

Desarrollo y variables

- Construcción de un inventario de documentos con metadatos básicos.
- Análisis de distribución por ministerio, organismo, fecha, tipo documental y longitud.
- Medición aproximada de calidad textual: caracteres no alfabéticos, líneas vacías, fragmentos repetidos, proporción de tokens válidos y presencia de OCR defectuoso.
- Identificación de documentos atípicos por longitud o falta de metadatos.

Métricas y resultados esperados

- Número total de documentos procesados y porcentaje con texto utilizable.
- Distribución por fuente y organismo.
- Histogramas de longitud y ranking de documentos más extensos.
- Conclusiones sobre qué subconjuntos son adecuados para cada mini caso.

Aplicación práctica

Este mini caso servirá como control de calidad y como justificación de decisiones posteriores de modelado.

7.2 Mini caso 2 - Clasificación automática de documentos

Planteamiento inicial

Se evaluará si el contenido textual permite predecir categorías de los documentos, como ministerio, organismo o tipo documental. La variable objetivo definitiva se decidirá tras el EDA, priorizando aquella que tenga suficiente número de ejemplos por clase.

Features previstas

- TF-IDF de palabras y n-gramas.
- Embeddings de documentos o fragmentos.
- Variables de longitud: número de tokens, frases y entidades.
- Entidades extraídas y palabras clave.

Modelos candidatos

- Baseline por clase mayoritaria y reglas simples.

- Naive Bayes y Logistic Regression como modelos interpretables.
- SVM lineal para textos de alta dimensionalidad.
- Random Forest o Gradient Boosting si las features tabulares aportan valor.

Evaluación

- Train/test split o validación cruzada estratificada.
- Accuracy como métrica general.
- F1 macro para controlar desbalanceo de clases.
- Matriz de confusión y análisis manual de errores.
- Interpretabilidad mediante términos más influyentes por clase.

Aplicación práctica

El clasificador podría servir para etiquetar documentos nuevos, detectar documentos mal categorizados o comprender qué vocabulario caracteriza a cada institución.

7.3 Mini caso 3 - Clustering temático y topic modeling

Planteamiento inicial

Se buscarán agrupaciones temáticas sin imponer categorías previas, con el objetivo de descubrir familias de documentos y narrativas comunes en el corpus.

Desarrollo

- Representación textual mediante TF-IDF y embeddings.
- Reducción de dimensionalidad con UMAP o PCA para visualización.
- Clustering con K-Means, clustering jerárquico y, si el corpus lo permite, BERTopic.
- Asignación de etiquetas interpretables a cada cluster mediante términos representativos y revisión manual de documentos prototipo.

Métricas y validación

- Silhouette score y Davies-Bouldin para comparación cuantitativa.
- Coherencia semántica de temas cuando se use topic modeling.
- Revisión cualitativa de documentos cercanos al centroide de cada cluster.
- Comparación de clusters con ministerio, organismo y fecha para detectar patrones institucionales o temporales.

Aplicación práctica

El resultado facilitará una navegación temática del corpus y permitirá resumir grandes bloques documentales sin leerlos manualmente uno a uno.

7.4 Mini caso 4 - Grafo de actores, instituciones y lugares

Planteamiento inicial

El proyecto analizará qué personas, instituciones y lugares aparecen relacionados dentro del corpus. La relación se definirá principalmente por coocurrencia dentro del mismo documento o, si es posible, dentro de una ventana textual más pequeña.

Feature engineering

- Extracción de entidades nombradas con spaCy y revisión manual de las entidades más frecuentes.
- Normalización de alias y variantes: por ejemplo, nombres propios, cargos militares, siglas e instituciones.
- Construcción de nodos por entidad y aristas por coocurrencia.
- Ponderación de aristas por frecuencia o intensidad de coaparición.

Métricas y análisis

- Degree centrality, betweenness centrality, eigenvector centrality y PageRank.
- Detección de comunidades con Louvain o algoritmos equivalentes.
- Identificación de entidades puente entre comunidades.
- Comparación de subgrafos por organismo o periodo.

Aplicación práctica

El grafo permitirá visualizar redes de actores y detectar qué instituciones o personas vertebran el conjunto documental.

7.5 Mini caso 5 - Análisis temporal y buscador semántico

Planteamiento inicial

La dimensión temporal es esencial para estudiar cómo cambian los temas y menciones antes, durante y después del golpe. Además, se propondrá un prototipo sencillo de búsqueda semántica para recuperar documentos relevantes por consulta en lenguaje natural.

Análisis temporal

- Normalización de fecha documental y extracción de fechas mencionadas dentro del texto.
- Agrupación por ventanas: antes del 23-F, días críticos, semanas posteriores, juicio y documentación posterior.
- Evolución de menciones a actores, organismos y temas.
- Visualización mediante líneas temporales y heatmaps actor-periodo.

Buscador semántico

- Generación de embeddings por documento y, si procede, por fragmentos.
- Búsqueda por similitud coseno frente a consultas en lenguaje natural.
- Comparación con una búsqueda TF-IDF como baseline.
- Evaluación manual con un pequeño conjunto de consultas: Tejero, CESID, juicio, apoyo internacional, Congreso, Zarzuela.

Evaluación

- Precision@5, MRR y revisión cualitativa para la recuperación.
- Consistencia temporal de temas y entidades.
- Análisis de errores: consultas demasiado generales, entidades ambiguas y documentos con OCR débil.

Aplicación práctica

Este mini caso transformará el análisis en una herramienta de consulta útil para usuarios no técnicos, permitiendo encontrar documentos relevantes sin conocer previamente sus títulos.

8. Plan de trabajo hasta la entrega final

El calendario propuesto organiza el trabajo en cuatro bloques: consolidación de datos, desarrollo de modelos, interpretación de resultados y cierre documental. La Figura A3 del anexo resume visualmente la planificación.

Periodo	Objetivo	Tareas principales	Resultado esperado
24 abril - 3 mayo	Entrega parcial	Repositorio, informe parcial, diseño de pipeline, inventario inicial.	Documento intermedio y estructura de Git.
4 - 10 mayo	Datos y EDA	Descarga/carga de documentos, limpieza, metadatos, EDA completo.	Dataset procesado y figuras descriptivas.
11 - 17 mayo	Modelos principales	Clasificación, clustering, embeddings y topic	Tablas de métricas y

		modeling.	visualizaciones.
18 - 24 mayo	Grafos y temporalidad	NER, grafo de entidades, línea temporal y buscador semántico.	Resultados interpretados y anexos.
25 - 31 mayo	Cierre final	Notebook reproducible, informe PDF, presentación, ZIP final.	Entrega final completa.

8.1 Reparto de responsabilidades sugerido

Rol	Responsabilidad	Entregables internos
Integración de datos	Ingesta, estructura de carpetas, limpieza y metadatos.	metadata.csv, scripts de preprocesado.
EDA y visualización	Calidad del dato, descriptivos y figuras.	Tablas y gráficos para informe.
Modelado supervisado	Clasificación, evaluación y análisis de errores.	Modelos, matriz de confusión, métricas.
No supervisado y NLP	Clustering, topics, embeddings y buscador.	Clusters, temas y evaluación manual.
Grafos y narrativa	NER, redes, temporalidad e interpretación.	Grafo, centralidades, timeline y conclusiones.

9. Organización del repositorio Git y reproducibilidad

El repositorio Git será obligatorio durante el desarrollo. La estructura propuesta busca separar datos, notebooks, scripts, resultados y documentación. El notebook principal funcionará como punto de entrada y llamará a funciones definidas en scripts auxiliares.

Ruta	Contenido	Uso
README.md	Descripción del proyecto, instrucciones de ejecución y autores.	Entrada al repositorio.
requirements.txt	Librerías necesarias.	Reproducibilidad.
notebooks/00_main_pipeline.ipynb	Notebook principal ejecutable de principio a fin.	Entrega técnica.
src/	Scripts de descarga, limpieza, features, modelos y visualización.	Código modular.
data/raw/	Datos originales o enlaces controlados.	Trazabilidad.
data/interim/	Textos y metadatos intermedios.	Depuración.
data/processed/	Dataset final procesado.	Entrada a modelos.
outputs/figures/	Figuras del informe y anexos.	Documentación.
outputs/models/	Modelos entrenados si procede.	Reutilización.
docs/	Informe parcial, informe final y presentación.	Entregables.

Criterios de reproducibilidad

- Todas las rutas serán relativas al directorio raíz del proyecto.
- El notebook principal se podrá ejecutar de principio a fin sin modificar rutas manualmente.

- Los scripts auxiliares estarán documentados y versionados.
- Los resultados intermedios pesados se guardarán en carpetas separadas y, si es necesario, se excluirán de Git mediante .gitignore.
- Las figuras usadas en el informe se generarán desde el código o quedarán documentadas en el repositorio.

10. Riesgos, limitaciones y plan de mitigación

Riesgo	Impacto	Mitigación
OCR ruidoso o textos incompletos	Reduce la calidad de NLP y modelos.	Medir calidad, limpiar y excluir casos extremos si es necesario.
Clases desbalanceadas	Puede inflar accuracy y reducir utilidad del clasificador.	Usar F1 macro, validación estratificada y análisis por clase.
Entidades duplicadas o ambiguas	Distorsiona el grafo.	Normalización manual de entidades principales y diccionario de alias.
Pocos datos para modelos complejos	Riesgo de sobreajuste.	Priorizar modelos interpretables y validación cruzada.
Clusters difíciles de interpretar	Resultados poco comunicables.	Combinar métricas con revisión manual de documentos prototipo.
Rutas absolutas o dependencias no documentadas	Entrega no reproducible.	requirements.txt, rutas relativas y prueba de ejecución limpia.
Informe demasiado extenso	Incumplimiento del límite de páginas.	Cuerpo principal sintético y gráficos/tablas grandes en anexos.

11. Conclusiones de la entrega parcial

La propuesta presentada cumple el objetivo de la entrega intermedia: define una estructura clara del trabajo, describe las iniciativas de análisis y concreta cómo se abordará cada mini caso. El proyecto se plantea como una investigación documental apoyada en Machine Learning, con especial énfasis en la reproducibilidad, la interpretación y la utilidad práctica.

La combinación de EDA, clasificación, clustering, grafos, análisis temporal y búsqueda semántica permite cubrir distintas áreas de conocimiento y construir una narrativa sólida sobre el corpus. La fase siguiente consistirá en consolidar el dataset procesado, ejecutar los modelos, evaluar resultados y transformar los hallazgos en un informe final claro y defendible.

12. Referencias

1. Enunciado de la asignatura: Proyecto ML 2025-2026. Documento facilitado por el profesorado.
2. RTVE. (2026). Buscador 23F | Lee y explora todos los documentos desclasificados con ayuda de la IA. <https://www.rtve.es/noticias/20260227/buscador-23f-lee-explora-todos-documentos-desclasificados-con-ayuda-ia/16956459.shtml>
3. RTVE. (2026). Todos los documentos desclasificados del 23F: consulta la lista íntegra. <https://www.rtve.es/noticias/20260225/todos-documentos-desclasificados-23f-lista-integra/16954095.shtml>
4. RTVE. (2026). RTVE crea con IA el buscador de documentos desclasificados del 23-F. <https://www.rtve.es/rtve/20260227/rtve-crea-ia-buscador-documentos-desclasificados-23-f/16957045.shtml>
5. La Moncloa. (2026). Documentos desclasificados relativos al 23-F. <https://www.lamoncloa.gob.es/consejodem Ministros/paginas/desclasificacion-documentos-23f.aspx>

6. Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research.
7. Honnibal, M. & Montani, I. spaCy 2: Natural language understanding with Bloom embeddings, convolutional neural networks and incremental parsing.
8. McInnes, L., Healy, J. & Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction.




Figura A3. Calendario orientativo hasta la entrega final.

Anexo B - Checklist de entrega intermedia

Elemento	Estado	Comentario
Informe parcial	Preparado	Documento actual.
Estructura inicial del trabajo	Preparado	Incluida en secciones 5, 7 y 9.
Propuesta de análisis	Preparado	Cinco mini casos definidos.
Enlace al repositorio Git	Preparado	URL real incorporada en portada y documentación del repositorio.
Permisos al repositorio	Preparado	Dar acceso al profesor o correo indicado.
Nombres del equipo	Preparado	Portada actualizada con los nombres reales del equipo.

Anexo C - Estructura técnica propuesta

```
proyecto-ml-23f/  
|-- README.md  
|-- requirements.txt  
|-- notebooks/  
|   |-- 00_main_pipeline.ipynb  
|-- src/  
|   |-- data_download.py  
|   |-- preprocessing.py  
|   |-- eda.py  
|   |-- nlp_features.py  
|   |-- classification.py  
|   |-- clustering.py  
|   |-- graph_analysis.py  
|   |-- temporal_analysis.py  
|   |-- utils.py  
|-- data/      (raw/, interim/, processed/)  
|-- outputs/   (figures/, tables/, models/)  
|-- docs/      (informe_intermedio.pdf, informe_final.pdf)
```